



Mạng thần kinh tích chập

Mạng nơ-ron tích chập (tiếng Anh: *Convolutional Neural Network*, viết tắt: **CNN** hay **ConvNet**) là một lớp các mạng nơ-ron sâu trong học sâu (deep learning), được thiết kế đặc biệt để xử lý và phân tích các dữ liệu có cấu trúc lưới nhiều chiều, phổ biến nhất là hình ảnh hai chiều.^[1]

Khác với các mạng nơ-ron kết nối đầy đủ (MLP/FC), CNN tận dụng hai nguyên lý không gian cốt lõi: **sự kết nối cục bộ** (local connectivity) và **chia sẻ trọng số** (weight sharing). Nhờ đó, CNN giảm thiểu đáng kể số lượng tham số cần huấn luyện, hạn chế hiện tượng quá khớp (overfitting) và có khả năng trích xuất các đặc trưng học được mang tính bất biến tịnh tiến (translation invariance).^[2]

Lịch sử phát triển

- **Ý tưởng sinh học ban đầu (1959–1962):** David Hubel và Torsten Wiesel nghiên cứu võ não thị giác của mèo và phát hiện ra các tế bào thần kinh có trường tiếp nhận (receptive field) cục bộ, chia làm tế bào đơn giản (simple cells) và tế bào phức tạp (complex cells). Khám phá này đã mang về cho họ giải Nobel Y học năm 1981 và đặt nền móng sinh học cho CNN.^[3]
- **Neocognitron (1980):** Kunihiko Fukushima đề xuất mô hình Neocognitron, kiến trúc nhân tạo đầu tiên kết hợp các lớp tích chập và lớp gom cụm (pooling), có khả năng nhận dạng mẫu không phụ thuộc vào vị trí.^[4]
- **LeNet-5 (1998):** Yann LeCun và các đồng sự tại AT&T Labs đã kết hợp phép tích chập với thuật toán lan truyền ngược (backpropagation) để tạo ra LeNet-5, mô hình nhận dạng chữ số viết tay trên séc ngân hàng thành công thương mại đầu tiên.^[5]
- **Bước ngoặt AlexNet (2012):** Alex Krizhevsky, Ilya Sutskever và Geoffrey Hinton phát triển AlexNet, sử dụng GPU để huấn luyện mạng CNN sâu trên tập dữ liệu ImageNet và giành chiến thắng áp đảo tại cuộc thi ILSVRC 2012. Bước ngoặt này mở ra kỷ nguyên bùng nổ của học sâu.^[6]

Kiến trúc cốt lõi

Một kiến trúc CNN tiêu chuẩn được cấu tạo bởi sự xếp chồng liên tiếp của các lớp chính sau:

1. Lớp tích chập (Convolutional Layer)

Là thành phần cốt lõi thực hiện tính toán nặng nhất của mạng. Lớp này sử dụng một tập hợp các bộ lọc (filters/kernels) có kích thước nhỏ (ví dụ: 3×3 hoặc 5×5) trượt qua toàn bộ chiều rộng và chiều cao của ảnh đầu vào.

Tại mỗi vị trí trượt, phép tích chập tính tích vô hướng (dot product) giữa các trọng số của bộ lọc và vùng giá trị điểm ảnh tương ứng:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i - m, j - n) K(m, n)$$

Trong đó I là ma trận ảnh đầu vào, K là ma trận bộ lọc (kernel), và $S(i, j)$ là bản đồ đặc trưng (feature map) thu được.

Các tham số điều khiển phép tích chập gồm:

- **Kích thước bộ lọc (Kernel size):** Độ rộng và cao của cửa sổ trượt.
- **Bước trượt (Stride):** Số điểm ảnh mà bộ lọc di chuyển mỗi bước.
- **Đệm (Padding):** Thêm các giá trị (thường là 0 - *Zero-padding*) xung quanh viền ảnh để kiểm soát kích thước không gian của bản đồ đặc trưng đầu ra.

2. Lớp kích hoạt (Activation Layer)

Ngay sau phép tích chập tuyến tính, một hàm kích hoạt phi tuyến được áp dụng cho từng phần tử để giúp mạng học được các mối quan hệ phức tạp. Hàm kích hoạt chuẩn mực trong CNN hiện đại là **ReLU** (Rectified Linear Unit):

$$f(x) = \max(0, x)$$

3. Lớp gộp / Lớp lấy mẫu (Pooling Layer)

Lớp này giảm kích thước không gian (giảm chiều) của bản đồ đặc trưng, giúp giảm số lượng tham số tính toán và tạo ra tính bất biến đối với những biến đổi nhẹ/dịch chuyển của vật thể.

- **Max Pooling:** Lấy giá trị lớn nhất trong cửa sổ trượt (phổ biến nhất).
- **Average Pooling:** Lấy giá trị trung bình cộng các giá trị trong cửa sổ.

4. Lớp kết nối đầy đủ (Fully Connected Layer)

Nằm ở các tầng cuối cùng của mạng. Sau khi các lớp tích chập và pooling trích xuất các đặc trưng cấp cao, dữ liệu được trải phẳng (flatten) thành một vectơ một chiều và đưa qua các lớp kết nối đầy đủ để thực hiện nhiệm vụ phân loại hoặc dự đoán (thường dùng Softmax ở lớp đầu ra).

Các kiến trúc kinh điển

Các cột mốc kiến trúc CNN quan trọng

Mạng	Năm	Số lớp	Độ chính xác Top-5 (ImageNet)	Đóng góp chính
LeNet-5	1998	5	—	Kiến trúc Tích chập + Pooling + FC chuẩn mực đầu tiên.
AlexNet	2012	8	84.7%	Áp dụng ReLU, Dropout và huấn luyện song song trên GPU.
VGG-16	2014	16	92.7%	Đồng nhất hóa kiến trúc bằng các bộ lọc nhỏ 3×3 xếp chồng.
GoogLeNet	2014	22	93.3%	Giới thiệu khối Inception giúp tính toán đặc trưng ở nhiều tỉ lệ khác nhau.
ResNet	2015	152	96.4%	Giới thiệu kết nối tắt (Skip Connections/Residual Blocks), giải quyết triệt để bài toán biến mất đạo hàm (vanishing gradient). ^[7]
EfficientNet	2019	Biến đổi	97.1%	Tối ưu hóa đồng thời cả chiều sâu, chiều rộng và độ phân giải ảnh (Compound Scaling). ^[8]

So sánh với Mạng nơ-ron truyền thống (MLP)

So sánh CNN và Perceptron đa lớp (MLP)

Tiêu chí	Mạng Perceptron đa lớp (MLP)	Mạng nơ-ron tích chập (CNN)
Kết nối	Kết nối đầy đủ (mọi nơ-ron nối với mọi nơ-ron lớp trước)	Kết nối cục bộ (chỉ nối trong trường tiếp nhận)
Tham số	Rất lớn (tăng theo cấp số nhân với kích thước ảnh)	Nhỏ hơn rất nhiều nhờ cơ chế chia sẻ trọng số (weight sharing)
Xử lý không gian	Làm phẳng ảnh làm mất hoàn toàn cấu trúc không gian 2D	Giữ nguyên cấu trúc không gian và mối tương quan giữa các điểm ảnh lân cận
Tính chất	Nhạy cảm với vị trí vật thể	Bất biến với sự dịch chuyển nhẹ của vật thể trong ảnh

Ứng dụng

CNN là công nghệ nền tảng thống trị trong nhiều lĩnh vực:

- Thị giác máy tính:** Phân loại ảnh, phát hiện vật thể (YOLO, R-CNN), phân đoạn hình ảnh (U-Net).
- Y tế:** Phân tích ảnh chụp X-quang, MRI, CT để chẩn đoán khối u và các bệnh lý tự động.
- Xe tự lái:** Nhận diện làn đường, biển báo giao thông và người đi bộ theo thời gian thực.
- Xử lý ngôn ngữ tự nhiên:** Phân tích cảm xúc văn bản, phân loại câu (dùng tích chập 1D trên chuỗi từ).
- Sinh học tính toán:** Dự đoán sự cuộn gập cấu trúc ADN và Protein.

Xem thêm

- [Học sâu](#)
- [Học máy](#)
- [Thị giác máy tính](#)
- [Thần kinh học tính toán](#)
- [Học chuyển giao](#)

Tham khảo

1. LeCun, Yann; Bengio, Yoshua; Hinton, Geoffrey (2015). "Deep learning". *Nature*. **521** (7553): 436–444. doi:10.1038/nature14539. PMID 26017442.
2. Goodfellow, Ian; Bengio, Yoshua; Courville, Aaron (2016). *Deep Learning*. MIT Press. tr. 326–366. ISBN 978-0262035613.
3. Hubel, D. H.; Wiesel, T. N. (1962). "Receptive fields, binocular interaction and functional architecture in the cat's visual cortex". *The Journal of Physiology*. **160** (1): 106–154. doi:10.1113/jphysiol.1962.sp006837.
4. Fukushima, Kunihiko (1980). "Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position". *Biological Cybernetics*. **36** (4): 193–202. doi:10.1007/BF00344251.
5. LeCun, Yann; Bottou, Léon; Bengio, Yoshua; Haffner, Patrick (1998). "Gradient-based learning applied to document recognition". *Proceedings of the IEEE*. **86** (11): 2278–2324. doi:10.1109/5.726791.
6. Krizhevsky, Alex; Sutskever, Ilya; Hinton, Geoffrey E. (2012). "ImageNet classification with deep convolutional neural networks". *Advances in Neural Information Processing Systems (NeurIPS)*. tr. 1097–1105.
7. He, Kaiming; Zhang, Xiangyu; Ren, Shaoqing; Sun, Jian (2016). "Deep Residual Learning for Image Recognition". *CVPR*. tr. 770–778. arXiv:1512.03385.
8. Tan, Mingxing; Le, Quoc V. (2019). "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks". *ICML*. tr. 6105–6114. arXiv:1905.11946.

Liên kết ngoài

- [CS231n: Convolutional Neural Networks for Visual Recognition \(https://cs231n.github.io/\)](https://cs231n.github.io/) — Khóa học thị giác máy tính nổi tiếng của Stanford do [Andrej Karpathy](#) giảng dạy.
- [Hướng dẫn xây dựng CNN cơ bản với TensorFlow/Keras \(https://www.tensorflow.org/tutorials/s/images/cnn\)](https://www.tensorflow.org/tutorials/s/images/cnn)

Lấy từ "https://vi.wikipedia.org/w/index.php?title=Mạng_thần_kinh_tích_chập&oldid=75349660"